

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÀI TẬP KẾT THÚC MÔN HỌC

THIẾT KẾ VÀ PHÂN TÍCH THỰC NGHIỆM

Báo Cáo Phân Tích Mô Hình mlc_churn Bằng
Random Forest

Giảng viên: Assoc.Prof. Nguyễn Hải Châu

Sinh viên: Nguyễn Quang Vinh

Mã sinh viên: 23020579

Lớp học phần : INT3228E 1

Mục lục

1. Xây Dựng Mô Hình Cơ Sở (Mô hình M)	3
1.1. Tiền xử lý dữ liệu và Lựa chọn biến	3
1.2. Đánh giá Mô hình M ban đầu	4
2. Thí Nghiệm CRD	4
2.1. Kiểm định tính đồng nhất của phương sai (Levene's Test)	4
2.2. Đánh giá sự ảnh hưởng của yếu tố k bằng OLS và Tukey HSD	5
3. Thí Nghiệm CRFD (Completely Randomized Factorial Design)	8
3.1. Phân tích phương sai ANOVA 2 chiều	8
3.2. Ước lượng hệ số và Khoảng tin cậy bằng OLS	9
3.3. Đồ thị phân tích tương tác	10
4. Kết Luận	11

Danh sách hình ảnh

Hình 1: bảng phân tích OLS	5
Hình 2: Bảng phân tích TUKEY HSD	6
Hình 3 đồ thị so sánh 3 nhóm dựa trên kết quả của TukeyHSD	7
Hình 4 Bảng phân tích phương sai ANOVA 2 chiều	8
Hình 4 Bảng hệ số OLS	9
Hình 5 Đồ thị phân tích tương tác của k và max_depth	10

1. Xây Dựng Mô Hình Cơ Sở (Mô hình M)

1.1. Tiền xử lý dữ liệu và Lựa chọn biến

Bộ dữ liệu `mlc_churn` ghi nhận thông tin sử dụng dịch vụ và trạng thái rời mạng (churn) của khách hàng.

Trong pha tiền xử lý, đã mã hóa biến mục tiêu churn (`yes = 1`, `no = 0`).

Dựa trên ma trận tương quan tuyến tính (Pearson correlation) và ý nghĩa thực tiễn, nhóm biến về cước phí bao gồm: `total_day_charge`, `total_eve_charge`, `total_night_charge`, `total_intl_charge` bị loại bỏ. Lý do là các biến cước phí này được tính toán tỷ lệ trực tiếp (tương quan hoàn hảo > 0.95) từ các biến số phút gọi tương ứng (minutes). Việc giữ lại cả hai sẽ gây ra đa cộng tuyến, làm sai lệch kết quả đánh giá tầm quan trọng của biến trong mô hình. Đồng thời biến `number_vmail_messages` cũng được loại bỏ do tương quan mạnh với cấu hình đăng ký hộp thư thoại.

1.2. Đánh giá Mô hình M ban đầu

Mô hình cơ sở được xây dựng bằng thuật toán Random Forest (RF) với các siêu tham số (hyperparameters) mặc định. Tập dữ liệu được chia theo chiến lược Stratified (giữ nguyên tỷ lệ lớp rời mạng) với `random_seed = 1234`.

Hiệu năng của Mô hình M trên tập kiểm thử (đánh giá bằng độ đo F1-Score đối với lớp positive "yes") đạt giá trị cơ sở là: 0.7903.

2. Thí Nghiệm CRD

Thí nghiệm được thiết kế ngẫu nhiên hoàn toàn để đánh giá ảnh hưởng của số lượng fold ($k = 3, 5, 10$) đến hiệu năng mô hình (F1-score) khi áp dụng k-fold với 10 lần lặp.

2.1. Kiểm định tính đồng nhất của phương sai (Levene's Test)

Trước khi phân tích ANOVA, kiểm định Levene được tiến hành để xác nhận tính đồng nhất của phương sai giữa 3 nhóm cấu hình k.

Kết quả: Thống kê $p\text{-value} = 0.0585 > 0.05$. Do đó, không đủ cơ sở để bác bỏ giả thuyết H_0

Kết luận: Phương sai F1-score của các nhóm $k = 3, 5, 10$ là đồng nhất, thỏa mãn giả định để chạy mô hình OLS/ANOVA.

2.2. Đánh giá sự ảnh hưởng của yếu tố k bằng OLS và Tukey HSD

Mô hình OLS (tương đương với `lm()` trong R) được thiết lập với phương trình: $f1_score \sim C(k)$.

[2] BẢNG PHÂN TÍCH OLS (Giá trị trung bình và Khoảng tin cậy)							
	coef	std err	t	P> t	[0.025	0.975]	
Intercept	0.7840	0.006	125.075	0.000	0.772	0.796	
C(k) [T.5]	0.0112	0.008	1.407	0.161	-0.004	0.027	
C(k) [T.10]	0.0185	0.007	2.591	0.010	0.004	0.033	

Hình 1: bảng phân tích OLS

- **Nhóm cơ sở (k=3):** Hệ số chặn (Intercept) đạt giá trị trung bình là 0.7840, với khoảng tin cậy 95% nằm trong khoảng [0.772, 0.796]. Giá trị p-value xấp xỉ 0.000 khẳng định ước lượng này có ý nghĩa thống kê rất cao.
- **Nhóm k=5:** F1-Score trung bình tăng thêm 0.0112 so với nhóm cơ sở. Tuy nhiên, p-value = 0.161 (> 0.05) và khoảng tin cậy chứa giá trị 0 [-0.004, 0.027] cho thấy sự khác biệt này có thể do ngẫu nhiên và không mang ý nghĩa thống kê.
- **Nhóm k=10:** Mức tăng F1-Score là 0.0185 so với nhóm cơ sở. Với p-value = 0.010 (< 0.05) và khoảng tin cậy hoàn toàn dương [0.004, 0.033], có đủ bằng chứng thống kê để khẳng định việc tăng cấu hình lên 10 fold giúp cải thiện đáng kể hiệu năng của mô hình.


```
[3] BẢNG PHÂN TÍCH TUKEY HSD (So sánh cặp)
Multiple Comparison of Means - Tukey HSD, FWER=0.05
=====
group1 group2 meandiff p-adj    lower    upper    reject
-----
      3      5   0.0112 0.3392 -0.0076 0.0299   False
      3     10   0.0185 0.0279  0.0016 0.0354    True
      5     10   0.0074 0.4328 -0.0067 0.0214   False
-----
```

Hình 2: Bảng phân tích TUKEY HSD

Giữa k=3 và k=5: Giá trị $p\text{-adj} = 0.3392 (> 0.05)$, kết luận bác bỏ giả thuyết không (reject) là False. Mức chênh lệch hiệu năng là không đáng kể.

Giữa k=3 và k=10: Giá trị $p\text{-adj} = 0.0279 (< 0.05)$, kết luận bác bỏ là True. Điều này tái khẳng định cấu hình 10 fold đem lại sự vượt trội về F1-score so với cấu hình 3 fold, khoảng tin cậy chênh lệch dao động từ 0.0016 đến 0.0354.

Giữa k=5 và k=10: Giá trị $p\text{-adj} = 0.4328 (> 0.05)$, kết luận là False. Sự cải thiện khi tăng từ 5 lên 10 fold là chưa đủ lớn để tạo thành khác biệt có ý nghĩa thống kê.



Hình 3 đồ thị so sánh 3 nhóm dựa trên kết quả của TukeyHSD

Sự khác biệt thống kê: Trong kiểm định Tukey HSD, nếu các khoảng tin cậy của hai nhóm **không chồng lấp lên nhau**, chúng ta có thể kết luận rằng sự khác biệt giữa hai nhóm đó là **có ý nghĩa thống kê**.

- Khoảng tin cậy của $k=3$ và $k=10$ hoàn toàn tách biệt.
- Tuy nhiên, khoảng tin cậy của $k=5$ có sự giao thoa nhẹ với cả $k=3$ và $k=10$
- **Kết luận:** Sự khác biệt giữa $k=3$ và $k=10$ là rõ ràng nhất. Việc tăng số fold lên 10 mang lại hiệu quả F1-Score vượt trội hơn hẳn so với 3 fold.

3. Thí Nghiệm CRFD (Completely Randomized Factorial Design)

Thí nghiệm đa yếu tố được thiết kế với 2 biến độc lập: (1) Số fold $k \in \{3, 5, 10\}$ và (2) Siêu tham số $\text{max_depth} \in \{3, 5, \text{None}\}$. Mục tiêu là phân tích sự tác động đơn lẻ và sự tương tác giữa 2 yếu tố này đối với độ đo F1- Score.

3.1. Phân tích phương sai ANOVA 2 chiều

```
[1] BẢNG PHÂN TÍCH PHƯƠNG SAI (ANOVA 2 CHIỀU)
Đánh giá ý nghĩa thống kê tương tác của k và max_depth:
```

	sum_sq	df	F	PR(>F)
C(k)	0.003768	2.0	0.910923	0.402780
C(max_depth)	53.620331	2.0	12963.826914	0.000000
C(k):C(max_depth)	0.007269	4.0	0.878739	0.476365
Residual	1.098148	531.0	NaN	NaN

Hình 4 Bảng phân tích phương sai ANOVA 2 chiều

Từ bảng ANOVA, chỉ có yếu tố max_depth có p-value xấp xỉ 0.000, nhỏ hơn mức ý nghĩa 0.05. Sự tương tác giữa số fold k và độ sâu của cây max_depth có $p\text{-value} = 0.4763 > 0.05$. Điều này cho thấy không có hiệu ứng tương tác đáng kể giữa hai tham số này; nói cách khác, mức độ ảnh hưởng của độ sâu cây lên mô hình là độc lập với số k được chọn để kiểm định.

3.2. Ước lượng hệ số và Khoảng tin cậy bằng OLS


Sử dụng kết quả OLS để phân tích hệ số ảnh hưởng trung bình của từng nhóm cấu hình:

[2] BẢNG HỆ SỐ OLS (Giá trị trung bình và Khoảng tin cậy)						
	coef	std err	t	P> t	[0.025	0.975]
Intercept	0.0295	0.008	3.550	0.000	0.013	0.046
C(k) [T.5]	-0.0015	0.011	-0.138	0.890	-0.022	0.019
C(k) [T.10]	-0.0047	0.009	-0.493	0.622	-0.023	0.014
C(max_depth) [T.5]	0.3452	0.012	29.401	0.000	0.322	0.368
C(max_depth) [T.None]	0.7545	0.012	64.259	0.000	0.731	0.778
C(k) [T.5]:C(max_depth) [T.5]	0.0014	0.015	0.092	0.927	-0.028	0.031
C(k) [T.10]:C(max_depth) [T.5]	0.0115	0.013	0.860	0.390	-0.015	0.038
C(k) [T.5]:C(max_depth) [T.None]	0.0126	0.015	0.849	0.396	-0.017	0.042
C(k) [T.10]:C(max_depth) [T.None]	0.0232	0.013	1.732	0.084	-0.003	0.049

Hình 4 Bảng hệ số OLS

Bảng hệ số OLS chỉ ra rằng việc nói lỏng hoặc không giới hạn độ sâu của cây ($\text{max_depth} = \text{None}$) đóng vai trò quan trọng giúp mô hình Random Forest phân loại các trường hợp thiểu số (nhóm rời mạng), làm F1- score tăng lên mức cực đại (tăng thêm khoảng 0.75 so với cây bị giới hạn ở độ sâu bằng 3).

3.3. Đồ thị phân tích tương tác



Hình 5 Đồ thị phân tích tương tác của k và max_depth

Trên đồ thị, 3 đường đại diện cho 3 mức max_depth di chuyển theo quỹ đạo song song và không có sự giao cắt (hoặc cắt chéo) nhau. Độ dốc của các đường không thay đổi khi đi qua các giá trị k khác nhau. Hoàn toàn khớp với kết quả p-value của bảng ANOVA 2 chiều, xác nhận rằng không tồn tại sự tương tác giữa số fold và độ sâu của cây.

4. Kết Luận

Dựa trên 2 thí nghiệm thiết kế thực nghiệm:

Số lượng fold phân chia dữ liệu k có tác động nhất định đến khả năng dự đoán mô hình (tối ưu khi $k = 10$ do tăng lượng dữ liệu học ở mỗi fold), tuy nhiên khác biệt này là tương đối nhỏ lẻ tẻ.

Yếu tố chi phối lớn nhất đến F1-score của bộ dữ liệu cực đoan này là Độ sâu của cây quyết định(max_depth). Random Forest cần độ sâu lớn (None) để thiết lập đủ các nhánh tách logic chi tiết, tìm ra chân dung của nhóm khách hàng rời mạng chiếm thiểu số.

Không có sự tương tác đáng kể giữa 2 siêu tham số trên, cho phép việc tuning mô hình có thể được tối ưu độc lập từng tham số mà không lo nhiễu chéo.