

Bài tập kết thúc môn học

Thiết kế và phân tích thực nghiệm

1 Dữ liệu và yêu cầu chung

Bộ dữ liệu `mlc_churn` [1] chứa dữ liệu rời mạng viễn thông của các thuê bao ở một công ty viễn thông Mỹ. Mô tả về bộ dữ liệu có trong thư viện `tidymodels` [1] của R [2] (sử dụng lệnh `?mlc_churn`). Mỗi dòng trong bộ dữ liệu chứa thông tin sử dụng dịch vụ của một khách hàng trong một khoảng thời gian nhất định, ví dụ số phút gọi, số cuộc gọi, cước vào ngày, đêm, lễ, quốc tế..., vị trí địa lý, thời gian đã sử dụng dịch vụ của công ty.. và trạng thái rời mạng: `churn=yes` là đã rời mạng, `churn=no` ngược lại.

[2 điểm] Hãy sử dụng thuật toán Random Forests (RF) [3] để xây dựng một mô hình dự đoán khách hàng nào sẽ rời mạng căn cứ vào các biến đã nêu trên (mô hình M). Cần phải phân tích sử dụng hay loại bỏ biến nào bằng tương quan và ý nghĩa thực tiễn của các biến. Để phục vụ cho các yêu cầu thiết kế và phân tích thí nghiệm, chỉ cần thay đổi giá trị của siêu tham số (hyperparameter) `max_depth` và giữ giá trị mặc định của các siêu tham số khác. Để có thể tái hiện kết quả xây dựng mô hình, hãy sử dụng `random seed` là 1234 trong tất cả các thí nghiệm. Hiệu năng của mô hình được đánh giá bằng độ đo F1 (positive class = yes). Phân tích các kết quả thí nghiệm bằng `lm()` và có thể so sánh với `brm()` (không bắt buộc). Trong các so sánh, luôn phải có giá trị trung bình và khoảng tin cậy. Sinh viên có thể sử dụng Python, R, hoặc các ngôn ngữ lập trình khác để xây dựng mô hình RF.

Các phần tiếp theo mô tả yêu cầu bổ sung cho việc xây dựng mô hình và thiết kế, phân tích thí nghiệm.

2 Thí nghiệm CRD

Hãy thiết kế một thí nghiệm ngẫu nhiên hoàn toàn (Completely Randomized Design - CRD) [4] với phương pháp huấn luyện `repeated k-fold` với số lần lặp (`repeat`) là 10, k nhận các giá trị 3, 5, và 10. Do tỷ lệ khách hàng rời mạng thường thấp nên bộ dữ liệu bị mất cân bằng giữa hai nhóm khách hàng rời và không rời mạng. Bởi vậy, khi huấn luyện mô hình, cần phải sử dụng cách chia `fold stratified`. Yêu cầu:

- [1 điểm] So sánh phương sai của F1 khi k nhận các giá trị khác nhau bằng `leveneTest()`.
- [2 điểm] Đánh giá ảnh hưởng của k đến hiệu năng của mô hình và vẽ đồ thị so sánh 3 nhóm dựa trên kết quả của `TukeyHSD`.

3 Thí nghiệm CRFD

Hãy thiết kế một thí nghiệm đa yếu tố hoàn toàn ngẫu nhiên (Completely Randomized Factorial Design - CRFD) [4] với hai yếu tố: số fold $k = 3, 5, 10$ và siêu tham số `max_depth` nhận các giá trị 3, 5, và không giới hạn độ sâu của cây. Cách chia fold tương tự như thí nghiệm trước. Yêu cầu:

- [3 điểm] Đánh giá ảnh hưởng của k và `max_depth` đến hiệu năng của mô hình.
- [1 điểm] Kiểm tra ý nghĩa thống kê tương tác của k và `max_depth`, và ảnh hưởng của tương tác đến hiệu năng mô hình (nếu có). Vẽ đồ thị tương tác.

4 Viết báo cáo và nộp bài

[1 điểm] Hãy viết báo cáo mô tả quá trình xây dựng mô hình, thu thập dữ liệu hiệu năng mô hình và phân tích kết quả. Nộp bài trên hệ thống Canvas:

- Báo cáo ở định dạng PDF.
- 02 file dữ liệu kết quả của 2 thí nghiệm.

References

- [1] M. Kuhn, *modeldata: data sets useful for modeling examples*, 2025. R package version 1.5.1.
- [2] R. C. Team, “R: A language and environment for statistical computing. R foundation for statistical computing, Vienna, Austria,” 2024.
- [3] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, pp. 5–32, 2001.
- [4] J. Lawson, *Design and analysis of experiments with R*. CRC Press, 2015.